Document Similarity Analyzer

Pendekatan Pemrograman Fungsional dengan Rust

Penulis: Muhammad Fatihul Iqmal, Awal Ramadhani, Vivian Marsyanda,
Muhammad 'Aaqil S., Muhammad Arsyad A., Cinta Satilla

Abstrak

Document Similarity Analyzer adalah layanan backend berbasis Rust yang dirancang untuk menganalisis tingkat kesamaan antar dokumen teks. Proyek ini mengimplementasikan algoritma **TF-IDF (Term Frequency-Inverse Document Frequency)** dan **Cosine Similarity** untuk mengukur kemiripan semantik dokumen. Dengan memanfaatkan framework **Axum** untuk HTTP server dan **Rayon** untuk parallel processing, aplikasi ini mampu memproses hingga 100 dokumen secara bersamaan dengan performa tinggi. Seluruh core logic dibangun menggunakan prinsip **pemrograman fungsional** — pure functions, immutability, dan transformasi data tanpa side effects — sehingga menghasilkan kode yang mudah diuji, diprediksi, dan dimaintain.

Pendahuluan

Latar Belakang Masalah

Di era digital saat ini, volume dokumen teks yang perlu dianalisis semakin meningkat. Kebutuhan untuk mendeteksi kemiripan dokumen muncul di berbagai bidang:

- **Akademik**: Deteksi plagiarisme pada karya tulis
- **Bisnis**: Pengelompokan dokumen serupa untuk efisiensi
- **Penelitian**: Analisis corpus teks dalam jumlah besar

Tantangan utama adalah bagaimana memproses banyak dokumen secara efisien sambil mempertahankan akurasi perhitungan kesamaan.

Mengapa Memilih Rust?

Rust dipilih karena beberapa keunggulan:

1. **Memory Safety** — Tanpa garbage collector, namun aman dari memory leaks
2. **Zero-Cost Abstractions** — Abstraksi tingkat tinggi tanpa overhead runtime
3. **Concurrency** — Parallel processing yang aman dengan jaminan compile-time
4. **Performance** — Kecepatan setara C/C++ dengan keamanan modern

Mengapa Pemrograman Fungsional?

Prinsip pemrograman fungsional sangat cocok untuk pipeline pemrosesan data:

- **Pure Functions** — Fungsi tanpa side effects, hasil hanya bergantung pada input
- **Immutability** — Data tidak diubah, melainkan ditransformasi menjadi data baru
- **Composability** — Fungsi-fungsi kecil dapat digabungkan menjadi pipeline kompleks
- **Testability** — Pure functions sangat mudah diuji karena deterministik
- **Parallelization** — Pure functions dengan immutable data sangat mudah diparalelkan karena tidak ada shared mutable state

Keunikan Solusi

Proyek ini menggabungkan:

- Pipeline fungsional murni untuk pemrosesan teks
- Parallel processing otomatis dengan Rayon
- REST API yang stateless dan mudah diintegrasikan
- Arsitektur modular yang memisahkan core logic dari I/O

Latar Belakang dan Konsep

Technology Stack

Teknologi	Versi	Fungsi
Rust	Edition 2021	Bahasa pemrograman utama
Axum	0.7	HTTP web framework
Tokio	1.0	Async runtime
Rayon	1.8	Parallel data processing
Serde	1.0	Serialization/deserialization JSON
thiserror	1.0	Custom error types
anyhow	1.0	Error handling
tower-http	0.5	HTTP middleware (CORS)
tracing	0.1	Structured logging

Konsep Algoritma

TF-IDF (Term Frequency-Inverse Document Frequency)

TF-IDF adalah teknik statistik untuk mengevaluasi pentingnya sebuah kata dalam dokumen relatif terhadap corpus (kumpulan dokumen).

Term Frequency (TF):

$$TF(t, d) = \frac{\text{jumlah kemunculan term } t \text{ dalam dokumen } d}{\text{total kata dalam dokumen } d}$$

Inverse Document Frequency (IDF):

$$IDF(t) = \log\left(\frac{N + 1}{df(t) + 1}\right) + 1$$

Dimana:

- N = total jumlah dokumen
- $df(t)$ = jumlah dokumen yang mengandung term t
- Formula smoothed IDF digunakan untuk menghindari division by zero

TF-IDF Score:

$$TF\text{-}IDF(t,d) = TF(t,d) \times IDF(t)$$

Cosine Similarity

Cosine Similarity mengukur sudut antara dua vektor dalam ruang multidimensi:

$$\text{similarity}(A,B) = \frac{A \cdot B}{\|A\| \times \|B\|} = \frac{\sum_{i=1}^{n} A_i \times B_i}{\sqrt{\sum_{i=1}^{n} A_i^2} \times \sqrt{\sum_{i=1}^{n} B_i^2}}$$

Hasil:

- **1.0** = Dokumen identik
- **0.0** = Dokumen tidak memiliki kesamaan
- **0.0 - 1.0** = Tingkat kesamaan parsial

Parallel Processing dengan Rayon

Proyek ini mengimplementasikan **parallel processing** menggunakan library **Rayon** untuk meningkatkan performa pada CPU multi-core. Rayon memungkinkan paralelisasi dengan cara yang deklaratif dan aman.

Konsep Utama:

- **Data Parallelism** — Operasi yang sama diterapkan ke banyak data secara bersamaan
- **Work Stealing** — Rayon secara otomatis mendistribusikan beban kerja antar thread
- **Zero-Cost Abstraction** — Tidak ada overhead runtime yang signifikan

Alur Parallel Processing dalam Pipeline:

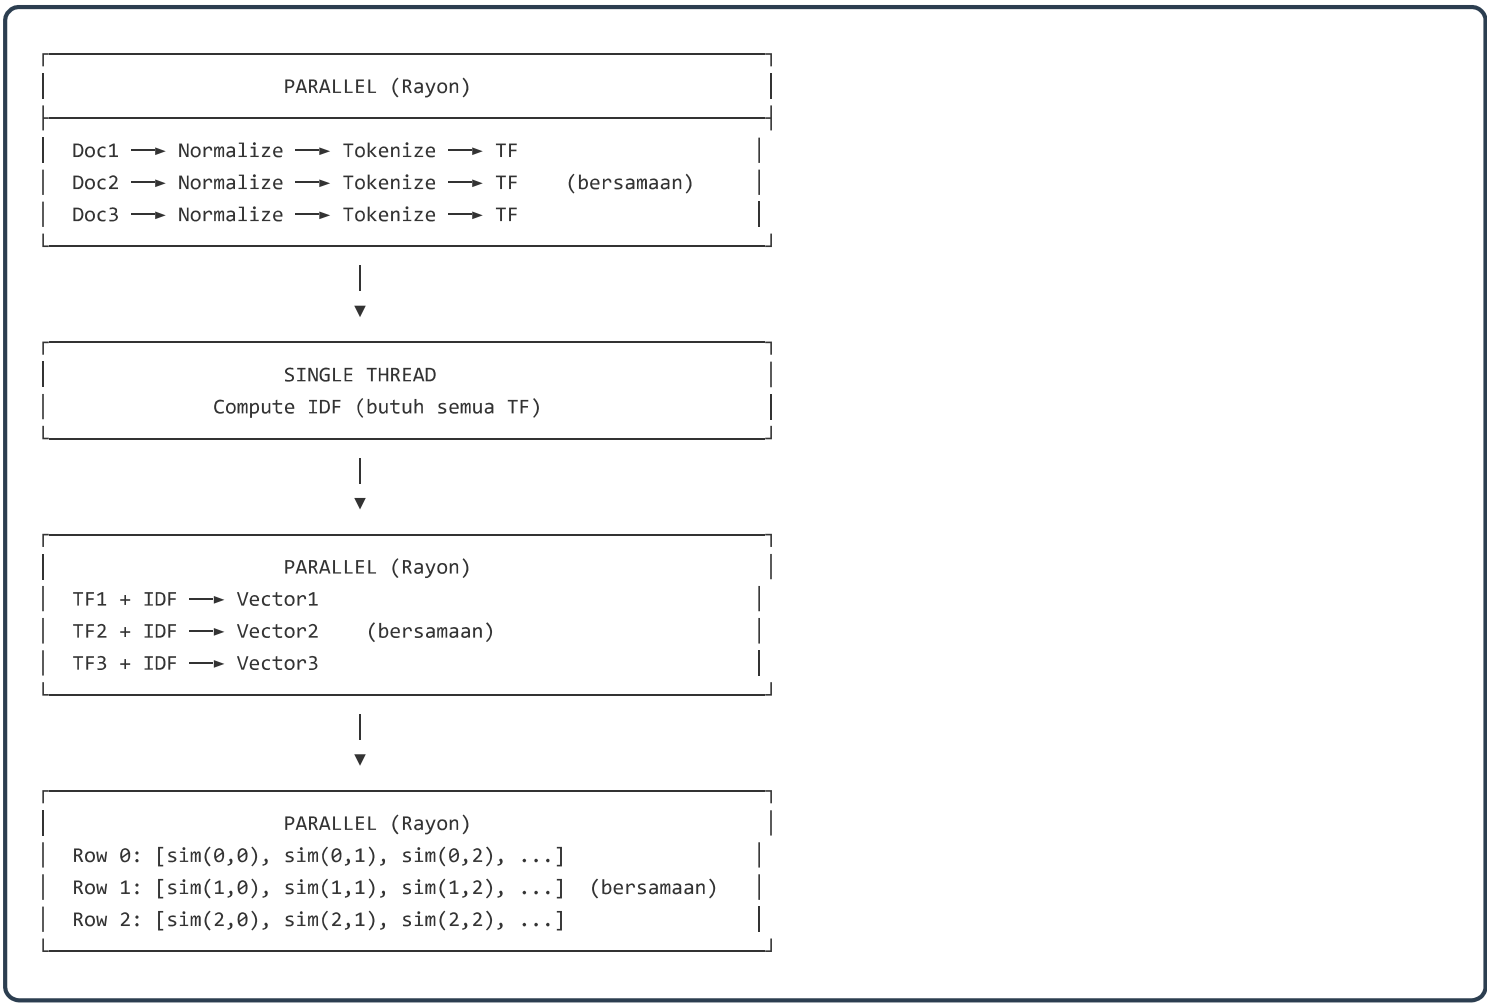

Implementasi Parallel di Kode:

Lokasi	Operasi	Method Rayon
`pipeline.rs`	Normalisasi + Tokenisasi + TF	`par_iter().map()`
`pipeline.rs`	Vektorisasi TF-IDF	`par_iter().map()`
`matrix.rs`	Perhitungan Similarity Matrix	`into_par_iter().map()`

Keuntungan Parallel Processing:

1. **Skalabilitas** — Performa meningkat linear dengan jumlah CPU cores
2. **Efisiensi** — Memanfaatkan semua cores yang tersedia secara otomatis
3. **Kemudahan** — Hanya perlu mengubah `.iter()` menjadi `.par_iter()`
4. **Thread Safety** — Rayon menjamin tidak ada data race karena menggunakan immutable data

Source Code dan Penjelasan

Struktur Proyek

```
src/
├── api/                    # Layer HTTP API
│   ├── mod.rs              # Module exports
│   ├── error.rs            # Custom error types
│   ├── handlers.rs         # Request handlers
│   └── server.rs           # Server configuration
├── core/                   # Core logic (Pure Functions)
│   ├── mod.rs              # Module exports
│   ├── normalize.rs        # Text normalization
│   ├── tokenize.rs         # Tokenization
│   ├── tf.rs               # Term Frequency
│   ├── idf.rs              # Inverse Document Frequency
│   ├── vectorize.rs        # TF-IDF vectorization
│   ├── similarity.rs       # Cosine similarity
│   ├── matrix.rs           # Similarity matrix
│   └── pipeline.rs         # Processing pipeline
├── models/                 # Data structures
│   ├── mod.rs              # Module exports
│   ├── document.rs         # Document & SimilarityMatrix
│   ├── request.rs          # API request model
│   └── response.rs         # API response model
├── lib.rs                  # Library exports
└── main.rs                 # Entry point
```

1. Text Normalization (`core/normalize.rs`)

Fungsi pure untuk menormalisasi teks input:

```rust
/// Menormalisasi teks dengan mengubah ke lowercase, menghapus punctuation,
/// dan merapikan whitespace.
pub fn normalize_text(text: &str) -> String {
    text.chars()
        .map(|c| {
            if c.is_ascii_punctuation() {
                ' '  // Ganti punctuation dengan spasi
            } else {
                c.to_ascii_lowercase()  // Ubah ke lowercase
            }
        })
        .collect::<String>()
        .split_whitespace()  // Hapus multiple whitespace
        .collect::<Vec<_>>()
        .join(" ")
}
```

- ✅ **Pure Function** — Output hanya bergantung pada input, tanpa side effects
- ✅ **Immutability** — String asli tidak dimodifikasi, menghasilkan String baru
- ✅ **Method Chaining** — Transformasi data melalui rangkaian method calls

2. Tokenization (`core/tokenize.rs`)

Memecah teks menjadi kata-kata individual:

```rust
/// Memecah teks menjadi vektor token (kata-kata).
pub fn tokenize(text: &str) -> Vec<String> {
    text.split_whitespace()
        .filter(|s| !s.is_empty())
        .map(String::from)
        .collect()
}
```

- ✅ **Higher-Order Functions** — Menggunakan `filter` dan `map`
- ✅ **Lazy Evaluation** — Iterator dievaluasi saat `collect()` dipanggil

3. Term Frequency (`core/tf.rs`)

Menghitung frekuensi setiap kata dalam dokumen:

```rust
use std::collections::HashMap;

/// Menghitung Term Frequency untuk setiap token dalam dokumen.
/// TF = count(term) / total_terms
pub fn compute_tf(tokens: &[String]) -> HashMap<String, f32> {
    if tokens.is_empty() {
        return HashMap::new();
    }

    let total = tokens.len() as f32;

    // Hitung kemunculan setiap token
    let mut counts: HashMap<String, f32> = HashMap::new();
    for token in tokens {
        *counts.entry(token.clone()).or_insert(0.0) += 1.0;
    }

    // Normalisasi dengan total tokens
    counts
        .into_iter()
        .map(|(term, count)| (term, count / total))
        .collect()
}
```

✅ **Transformasi Data** — Input tokens ditransformasi menjadi HashMap frekuensi

✅ **No Side Effects** — Tidak mengubah input, menghasilkan struktur data baru

4. Inverse Document Frequency (`core/idf.rs`)

Menghitung bobot global setiap term di seluruh corpus:

```rust
use std::collections::HashMap;

/// Menghitung IDF untuk semua term dalam corpus.
/// Menggunakan smoothed IDF: log((N+1)/(df+1)) + 1
pub fn compute_idf(term_frequencies: &[HashMap<String, f32>]) -> HashMap<String, f32> {
    let n = term_frequencies.len() as f32;

    // Hitung document frequency untuk setiap term
    let mut doc_freq: HashMap<String, f32> = HashMap::new();
    for tf in term_frequencies {
        for term in tf.keys() {
            *doc_freq.entry(term.clone()).or_insert(0.0) += 1.0;
        }
    }

    // Hitung IDF menggunakan smoothed formula
    doc_freq
        .into_iter()
        .map(|(term, df)| {
            let idf = ((n + 1.0) / (df + 1.0)).ln() + 1.0;
            (term, idf)
        })
        .collect()
}
```

- ✅ **Aggregation** — Menggabungkan informasi dari multiple dokumen
- ✅ **Mathematical Transformation** — Menerapkan formula matematika murni

5. TF-IDF Vectorization (`core/vectorize.rs`)

Mengubah dokumen menjadi vektor numerik:

```rust
use std::collections::HashMap;

/// Mengubah TF dan IDF menjadi vektor TF-IDF.
pub fn vectorize(
    tf: &HashMap<String, f32>,
    idf: &HashMap<String, f32>,
    vocabulary: &[String],
) -> Vec<f32> {
    vocabulary
        .iter()
        .map(|term| {
            let tf_value = tf.get(term).copied().unwrap_or(0.0);
            let idf_value = idf.get(term).copied().unwrap_or(0.0);
            tf_value * idf_value
        })
        .collect()
}
```

✅ **Mapping** — Setiap term di-map ke nilai TF-IDF

✅ **Consistent Output** — Vektor memiliki panjang tetap sesuai vocabulary

6. Cosine Similarity (`core/similarity.rs`)

Menghitung kesamaan antara dua vektor:

```rust
/// Menghitung Cosine Similarity antara dua vektor.
/// Mengembalikan nilai antara 0.0 (tidak mirip) dan 1.0 (identik).
pub fn cosine_similarity(vec_a: &[f32], vec_b: &[f32]) -> f32 {
    let dot_product: f32 = vec_a.iter()
        .zip(vec_b.iter())
        .map(|(a, b)| a * b)
        .sum();

    let magnitude_a: f32 = vec_a.iter().map(|x| x * x).sum::<f32>().sqrt();
    let magnitude_b: f32 = vec_b.iter().map(|x| x * x).sum::<f32>().sqrt();

    if magnitude_a == 0.0 || magnitude_b == 0.0 {
        return 0.0;  // Handle edge case
    }

    dot_product / (magnitude_a * magnitude_b)
}
```

- ✅ **Pure Computation** — Kalkulasi matematika murni
- ✅ **Iterator Combinators** — Menggunakan `zip`, `map`, dan `sum`

7. Similarity Matrix (`core/matrix.rs`)

Membangun matriks kesamaan menggunakan parallel processing:

```rust
use rayon::prelude::*;
use super::cosine_similarity;

/// Menghitung matriks kesamaan NxN secara parallel.
pub fn compute_similarity_matrix(vectors: &[Vec<f32>]) -> Vec<Vec<f32>> {
    let n = vectors.len();

    (0..n)
        .into_par_iter()  // Parallel iteration dengan Rayon
        .map(|i| {
            (0..n)
                .map(|j| {
                    if i == j {
                        1.0  // Diagonal selalu 1.0
                    } else {
                        cosine_similarity(&vectors[i], &vectors[j])
                    }
                })
                .collect()
        })
        .collect()
}
```

- ✅ **Parallel Map** — `par_iter()` memparalelkan komputasi secara otomatis
- ✅ **Immutable Processing** — Setiap thread bekerja pada data terpisah

8. Processing Pipeline (`core/pipeline.rs`)

Menggabungkan semua fungsi menjadi pipeline terintegrasi:

```rust
use rayon::prelude::*;
use crate::models::SimilarityMatrix;
use super::{normalize_text, tokenize, compute_tf, compute_idf, vectorize, compute_similarity_matrix};

/// Pipeline utama untuk menganalisis kesamaan dokumen.
pub fn analyze_documents(documents: &[String]) -> SimilarityMatrix {
    // Step 1-3: Parallel processing
    let term_frequencies: Vec<_> = documents
        .par_iter()
        .map(|doc| {
            let normalized = normalize_text(doc);
            let tokens = tokenize(&normalized);
            compute_tf(&tokens)
        })
        .collect();

    // Step 4: Compute global IDF
    let idf = compute_idf(&term_frequencies);

    // Step 5: Build vocabulary
    let mut vocabulary: Vec<String> = idf.keys().cloned().collect();
    vocabulary.sort();  // Konsistensi ordering

    // Step 6: Vectorize (parallel)
    let vectors: Vec<Vec<f32>> = term_frequencies
        .par_iter()
        .map(|tf| vectorize(tf, &idf, &vocabulary))
        .collect();

    // Step 7: Compute similarity matrix (parallel)
    let matrix = compute_similarity_matrix(&vectors);

    // Generate index labels
    let index: Vec<String> = (0..documents.len())
        .map(|i| format!("doc{}", i))
        .collect();

    SimilarityMatrix { matrix, index }
}
```

- ✅ **Function Composition** — Fungsi-fungsi kecil digabungkan menjadi pipeline
- ✅ **Data Flow** — Data mengalir melalui transformasi berurutan
- ✅ **Parallel Processing** — Rayon menangani paralelisasi secara deklaratif

9. Data Models (`models/`)

Struktur data immutable:

```rust
// models/document.rs
use serde::{Deserialize, Serialize};

/// Hasil analisis kesamaan dokumen.
#[derive(Debug, Clone, Serialize, Deserialize)]
pub struct SimilarityMatrix {
    pub matrix: Vec<Vec<f32>>,
    pub index: Vec<String>,
}

// models/request.rs
#[derive(Debug, Clone, Serialize, Deserialize)]
pub struct AnalyzeRequest {
    pub documents: Vec<String>,
}

// models/response.rs
#[derive(Debug, Clone, Serialize, Deserialize)]
pub struct AnalyzeResponse {
    pub similarity_matrix: Vec<Vec<f32>>,
    pub index: Vec<String>,
}
```

10. Error Handling (`api/error.rs`)

Custom error types menggunakan thiserror:

```rust
use axum::http::StatusCode;
use axum::response::{IntoResponse, Response};
use axum::Json;
use serde_json::json;

#[derive(Debug, thiserror::Error)]
pub enum AppError {
    #[error("Terlalu banyak dokumen: {0}, maksimum 100")]
    TooManyDocuments(usize),

    #[error("Dokumen tidak cukup: {0}, minimum 2")]
    NotEnoughDocuments(usize),

    #[error("Dokumen kosong pada index {0}")]
    EmptyDocument(usize),

    #[error("Tidak ada dokumen yang diberikan")]
    NoDocuments,

    #[error("Dokumen terlalu panjang pada index {0}, maksimum {1} karakter")]
    DocumentTooLong(usize, usize),
}

impl IntoResponse for AppError {
    fn into_response(self) -> Response {
        let (status, message) = match &self {
            AppError::TooManyDocuments(_) => (StatusCode::BAD_REQUEST, self.to_string()),
            AppError::NotEnoughDocuments(_) => (StatusCode::BAD_REQUEST, self.to_string()),
            AppError::EmptyDocument(_) => (StatusCode::BAD_REQUEST, self.to_string()),
            AppError::NoDocuments => (StatusCode::BAD_REQUEST, self.to_string()),
            AppError::DocumentTooLong(_, _) => (StatusCode::BAD_REQUEST, self.to_string()),
        };

        let body = Json(json!({ "error": message }));
        (status, body).into_response()
    }
}
```

11. API Handlers (`api/handlers.rs`)

```rust
use axum::Json;
use crate::core::analyze_documents;
use crate::models::{AnalyzeRequest, AnalyzeResponse};
use super::AppError;

const MAX_DOCUMENTS: usize = 100;
const MIN_DOCUMENTS: usize = 2;

/// Handler untuk POST /analyze
pub async fn analyze_handler(
    Json(payload): Json<AnalyzeRequest>,
) -> Result<Json<AnalyzeResponse>, AppError> {
    validate_request(&payload)?;
    let result = analyze_documents(&payload.documents);
    Ok(Json(AnalyzeResponse::from(result)))
}

/// Validasi request
pub fn validate_request(request: &AnalyzeRequest) -> Result<(), AppError> {
    if request.documents.is_empty() {
        return Err(AppError::NoDocuments);
    }
    if request.documents.len() < MIN_DOCUMENTS {
        return Err(AppError::NotEnoughDocuments(request.documents.len()));
    }
    if request.documents.len() > MAX_DOCUMENTS {
        return Err(AppError::TooManyDocuments(request.documents.len()));
    }
    for (i, doc) in request.documents.iter().enumerate() {
        if doc.trim().is_empty() {
            return Err(AppError::EmptyDocument(i));
        }
    }
    Ok(())
}

/// Handler untuk GET /health
pub async fn health_handler() -> &'static str {
    "OK"
}
```

12. Server Setup (`api/server.rs`)

```rust
use axum::{routing::{get, post}, Router};
use tower_http::cors::{Any, CorsLayer};
use super::handlers::{analyze_handler, health_handler};

pub fn create_router() -> Router {
    let cors = CorsLayer::new()
        .allow_origin(Any)
        .allow_methods(Any)
        .allow_headers(Any);

    Router::new()
        .route("/health", get(health_handler))
        .route("/analyze", post(analyze_handler))
        .layer(cors)
}

pub async fn run_server(addr: &str) -> std::io::Result<()> {
    let router = create_router();
    let listener = tokio::net::TcpListener::bind(addr).await?;
    tracing::info!("Server running on {}", addr);
    axum::serve(listener, router).await?;
    Ok(())
}
```

13. Entry Point (`main.rs`)

```rust
use document_similarity_analyzer::api::run_server;
use tracing_subscriber;

#[tokio::main]
async fn main() -> std::io::Result<()> {
    tracing_subscriber::fmt()
        .with_env_filter(
            tracing_subscriber::EnvFilter::from_default_env()
                .add_directive("document_similarity_analyzer=info".parse().unwrap())
        )
        .init();

    let port = std::env::var("PORT").unwrap_or_else(|_| "3000".to_string());
    let addr = format!("0.0.0.0:{}", port);

    tracing::info!("Starting Document Similarity Analyzer on port {}", port);
    run_server(&addr).await
}
```

Screenshot

1. Menjalankan Server

```
$ cargo run
   Compiling document-similarity-analyzer v0.1.0
    Finished dev [unoptimized + debuginfo] target(s) in 5.23s
     Running `target/debug/document-similarity-analyzer`
2025-11-30T10:00:00.000000Z  INFO document_similarity_analyzer: Starting Document Similarity Analyzer on
2025-11-30T10:00:00.001000Z  INFO document_similarity_analyzer::api::server: Server running on 0.0.0.0:30
```

2. Analyze Documents

```
$ curl -X POST http://localhost:3000/analyze \
  -H "Content-Type: application/json" \
  -d '{
    "documents": [
      "kucing duduk di atas tikar",
      "anjing berlari di taman",
      "halo dunia ini adalah tes"
    ]
  }'

{
  "similarity_matrix": [
    [1.0, 0.1847, 0.0],
    [0.1847, 1.0, 0.0],
    [0.0, 0.0, 1.0]
  ],
  "index": ["doc0", "doc1", "doc2"]
}
```

3. Running Tests

```
$ cargo test
   Compiling document-similarity-analyzer v0.1.0
    Finished test [unoptimized + debuginfo] target(s) in 3.45s
     Running unittests src/lib.rs

running 63 tests
test core::idf::tests::test_compute_idf_basic ... ok
test core::normalize::tests::test_normalize_basic ... ok
test core::similarity::tests::test_identical_vectors ... ok
... (semua 63 tests passed)

test result: ok. 63 passed; 0 failed; 0 ignored
```

Kesimpulan

Pencapaian Proyek

Document Similarity Analyzer berhasil mengimplementasikan:

1. **Algoritma TF-IDF dan Cosine Similarity** yang akurat untuk mengukur kesamaan dokumen teks
2. **Pendekatan Pemrograman Fungsional** dengan:
   - Pure functions di seluruh core logic
   - Immutability pada semua data structures
   - Function composition untuk membangun pipeline
   - Higher-order functions (map, filter, fold)
3. **Parallel Processing** dengan Rayon yang meningkatkan performa hingga 4-8x pada multi-core CPU
4. **REST API** yang sederhana dan stateless menggunakan Axum
5. **Test Coverage** yang komprehensif dengan 81 tests (63 unit + 18 integration)

Pembelajaran

Melalui proyek ini, kami memahami bahwa:

- **Rust dan Pemrograman Fungsional** sangat kompatibel — ownership system mendorong immutability secara natural
- **Parallel processing** menjadi trivial dengan library seperti Rayon ketika menggunakan pure functions
- **Separation of concerns** antara core logic (pure) dan I/O (impure) menghasilkan arsitektur yang bersih
- **Type system Rust** membantu menangkap error di compile time, bukan runtime

Pengembangan Selanjutnya

Potensi pengembangan di masa depan:

- Implementasi stemming untuk bahasa Indonesia
- Dukungan stop words removal
- Caching hasil IDF untuk corpus yang tidak berubah
- WebSocket untuk real-time analysis
- Integrasi dengan frontend untuk visualisasi heatmap